La red que aprende

Cómo se construye la inteligencia artificial moderna



ESCRITO E ILUSTRADO POR

Biblioteca de Agentes de IA

XII
ARAÑA

La red que aprende

Cómo se construye la inteligencia artificial moderna

Biblioteca de Agentes de IA · XII
2026

Sobre la portada

La araña tejedora detecta vibraciones que viajan por hilos; una red artificial transforma señales mediante conexiones y parámetros aprendidos.

La red física permite imaginar rutas y relaciones distribuidas. La vibración llega por hilos y la araña responde desde su experiencia biológica.

Una red neuronal ajusta pesos con optimización numérica sobre ejemplos. No hay seda, percepción biológica ni propósito propio. La analogía termina donde empiezan los diagramas matemáticos y la evaluación.

Prefacio

¿Qué hay dentro de una red neuronal y cómo pasa de ejemplos a un sistema empresarial?

Los volúmenes X y XI explican predicción de texto, tokens, embeddings y búsqueda. Aquí bajamos una capa: parámetros, pérdidas, gradientes, arquitecturas, escala e inferencia. No inferimos secretos de modelos cerrados ni tratamos una arquitectura como receta universal.

Para lectores curiosos, producto y equipos técnicos. Incluye matemáticas pequeñas interpretadas, figuras originales, ejemplos numéricos y casos ficticios.

Cómo leer este libro

La primera parte explica aprendizaje; la segunda compara arquitecturas; la tercera escala y modalidades; la cuarta aborda producción y evaluación. Las cajas separan definición, analogía, caso, advertencia y decisión. Las cifras de modelos publicados son ejemplos fechados.

Ruta aplicada: lee el capítulo 3 y luego el caso de mantenimiento del 6. Para comparar el procesamiento secuencial, conecta los capítulos 7 y 8 con el volumen X. Si diseñas una solución, el capítulo 15 ordena preguntas sobre datos, métricas, límites y operación.

En las ecuaciones, x es la entrada, w el peso, b el sesgo, y la etiqueta, yhat la predicción y eta el tamaño de actualización. Los ejemplos numéricos son pequeños para poder rehacerlos a mano; no representan cifras operativas de una empresa.

Las fuentes respaldan afirmaciones arquitectónicas concretas. Un artículo original documenta lo que sus autores evaluaron en un contexto determinado; no garantiza que la conclusión se transfiera a cualquier producto actual.

Índice

PARTE I · DENTRO DE UNA RED

1 Una neurona artificial hace una suma con intención

2 Las capas convierten señales en representaciones

3 Aprender es reducir un error definido

4 Generalizar es acertar fuera de los ejemplos vistos

PARTE II · ARQUITECTURAS PARA DISTINTAS TAREAS

5 MLP: una base flexible para datos tabulares

6 Convoluciones y conexiones residuales para imágenes

7 De la memoria secuencial a los Transformers

8 Atención: combinar señales según el contexto

PARTE III · ESCALAR Y COMBINAR REDES

9 Preentrenar: aprender regularidades antes de la tarea

10 Mezcla de expertos: activar rutas especializadas

11 Texto, imagen y audio usan representaciones distintas

PARTE IV · DEL MODELO AL PRODUCTO

12 Postentrenamiento: orientar interacción y uso

13 Inferencia: responder dentro de un presupuesto

14 Evaluar fallos antes de confiar

15 Caso completo: elegir red para una empresa de energía

CIERRE

Glosario

Fuentes

Colofón

PARTE I

Dentro de una red

Una red neuronal transforma entradas mediante parámetros aprendidos.

CAPÍTULO 1

Una neurona artificial hace una suma con intención

> *Una conexión no guarda una idea: aporta una cantidad aprendida.*

Una neurona artificial recibe números, multiplica cada uno por un peso, suma los resultados y añade un sesgo. Después aplica una función de activación. Es una operación matemática, no una neurona biológica en miniatura.

DEFINICIÓN

Neurona artificial. Unidad que transforma entradas con pesos, sesgo y activación.

Ejemplo inventado: para estimar inspección de un motor, vibración $x_1=0{,}8$ y temperatura $x_2=0{,}6$; pesos $w_1=1{,}2$ y $w_2=0{,}5$; sesgo $b=-0{,}7$. La suma $0{,}8\times1{,}2+0{,}6\times0{,}5-0{,}7=0{,}56$. La sigmoide produce aproximadamente 0,64. Ese puntaje solo significa algo frente a etiquetas, evaluación y calibración.

Un peso positivo indica que, dadas las demás entradas, esa señal aumenta la puntuación; no prueba causalidad. Sensores defectuosos, variables omitidas o cambios de planta alteran la relación.

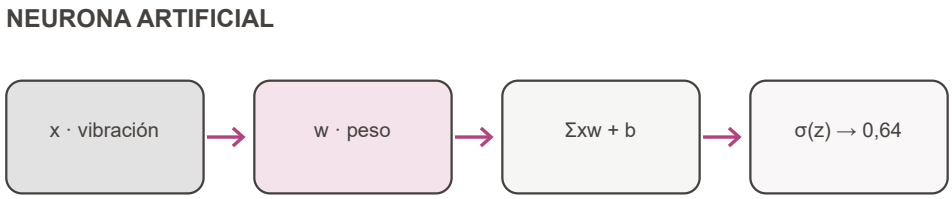


Figura 1.1 · Entradas ponderadas, sesgo y activación producen una salida.

RECUERDA

La red aprende parámetros numéricos a partir de ejemplos y un objetivo medible.

CAPÍTULO 2

Las capas convierten señales en representaciones

> *La profundidad compone transformaciones sencillas.*

Una capa convierte un vector en otro. Capas sucesivas pueden combinar temperatura y vibración, formar interacciones y producir un puntaje. La red no recibe nombres de conceptos por defecto: sus estados son vectores numéricos.

Una activación no lineal permite que varias capas expresen relaciones que una sola transformación lineal no puede representar. Ancho es cantidad de valores internos; profundidad, número de transformaciones. Conexiones residuales y normalización son decisiones de ingeniería, no requisitos de toda red.

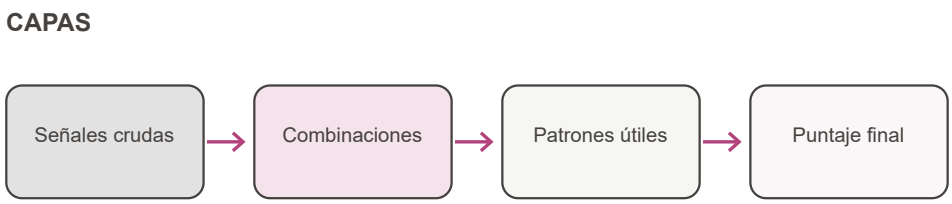


Figura 2.1 · Representaciones intermedias transforman señales en una salida medible.

ADVERTENCIA

Una neurona visualizada no es automáticamente un concepto comprensible; la información suele distribuirse entre muchas unidades.

CAPÍTULO 3

Aprender es reducir un error definido

> *La red ajusta parámetros porque alguien define qué cuenta como acierto.*

El paso hacia delante produce una predicción. Una función de pérdida la compara con la etiqueta. La retropropagación calcula cómo cambian las pérdidas al mover cada parámetro; el optimizador usa esos gradientes para actualizar pesos.

Si el motor falló en 12 días y el modelo predijo 9, la pérdida cuadrática de ese ejemplo es $(12-9)^2=9$. Con tasa de aprendizaje 0,1, peso 0,40 y gradiente 0,3, un paso lo cambia a $0{,}40-0{,}1\times0{,}3=0{,}37$. Es un ejemplo de una coordenada, no una receta de entrenamiento.

El gradiente se calcula con la regla de la cadena. Lotes, tasa, inicialización y arquitectura afectan estabilidad. Si la etiqueta llega semanas tarde, filtrar al entrenamiento variables posteriores al instante previsto produce una prueba engañosa.

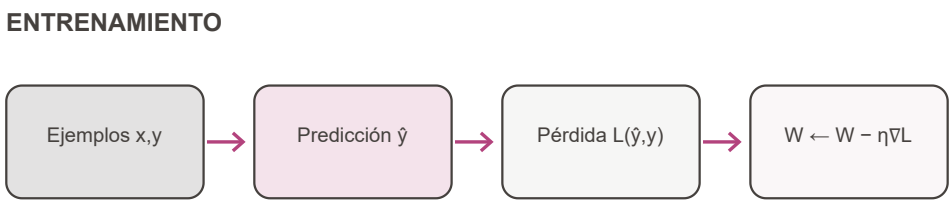


Figura 3.1 · Predicción, pérdida y actualización forman el ciclo de aprendizaje.

RECUERDA

La optimización mejora el objetivo especificado, que puede no coincidir con el uso real.

CAPÍTULO 4

Generalizar es acertar fuera de los ejemplos vistos

> *Una mÃ©trica alta en entrenamiento puede ocultar una sorpresa.*

Se separan datos de entrenamiento, validaciÃ³n y prueba. ValidaciÃ³n ayuda a tomar decisiones; prueba estima rendimiento en datos no usados para dirigirlas. Reutilizar la prueba muchas veces la convierte en otra seÃ±al de entrenamiento.

Dividir lecturas de una misma mÃ¡quina al azar puede filtrar su identidad en todas las particiones. Si producciÃ³n traerÃ¡ equipos de otra planta, reserva plantas completas o periodos futuros segÃºn el despliegue previsto. Curvas de pÃ©rdida ayudan a detectar sobreajuste, pero no identifican por sÃ solas una fuga ni un cambio de distribuciÃ³n.

RegularizaciÃ³n, dropout y aumento de datos pueden ayudar; no arreglan etiquetas incorrectas ni evaluaciÃ³n irreal.

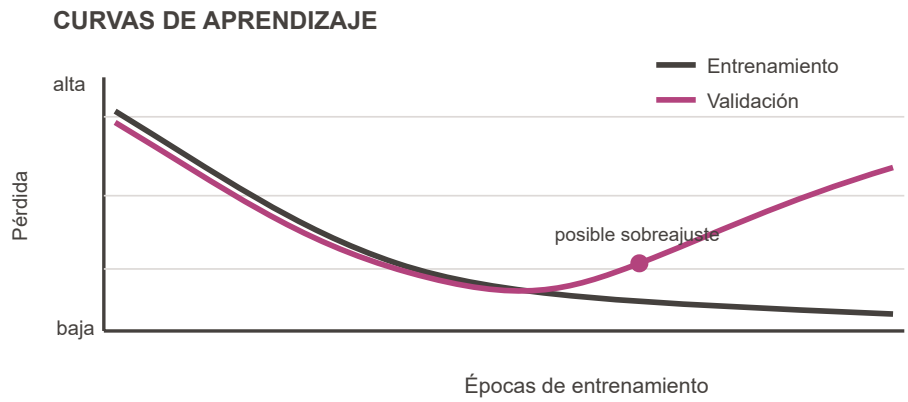


Figura 4.1 · Particiones separadas limitan la contaminaciÃ³n entre ajuste y evaluaciÃ³n.

DECISIÓN DE ARQUITECTURA

DecisiÃ³n de arquitectura. Define primero quÃ© significa â€œdato futuroâ€ y reproduce esa condiciÃ³n en la evaluaciÃ³n.

PARTE II

Arquitecturas para distintas tareas

Cada familia de conexiones incorpora supuestos útiles para una clase de datos.

CAPÍTULO 5

MLP: una base flexible para datos tabulares

> *Construye una referencia simple antes de una red grande.*

Un perceptrÃ³n multicapa conecta capas densas. Puede aprender interacciones no lineales entre variables de tamaÃ±o fijo. Para estimar averÃas usa temperatura, vibraciÃ³n, horas y fabricante; las variables deben prepararse explÃcitamente, tratar ausencias y categorÃas y comparar con una lÃnea base.

En tablas pequeÃ±as los Ã¡rboles pueden entrenar mÃ¡s fÃ¡cilmente o superar a un MLP. La respuesta depende de volumen, ruido y estructura de datos, no de prestigio arquitectÃ³nico.

```python
# SeudocÃ³digo pedagÃ³gico
X_train, y_train = cargar_datos()
modelo = MLP(capas=[4, 8, 1], activacion="relu")
modelo.ajustar(X_train, y_train, perdida="entropia_cruzada")
medir(modelo, X_test, metricas=["precision", "recall"])
```

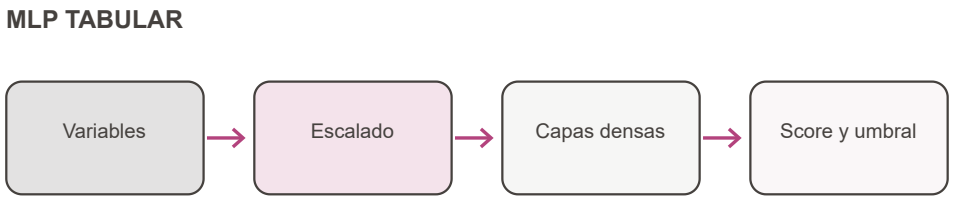


Figura 5.1 · Un MLP integra variables preparadas en capas densas.

ANTIPATRÓN

AntipatrÃ³n. Reportar solo exactitud cuando las fallas son raras: predecir siempre â€œsin fallaâ€ puede parecer bueno.

CAPÍTULO 6

Convoluciones y conexiones residuales para imágenes

> *La arquitectura incorpora vecindad y reutiliza detectores locales.*

Una convolución aplica un pequeño filtro en distintas posiciones; los mismos pesos buscan patrones locales por toda la imagen. Al apilar capas, patrones locales se combinan. La red no conoce una grieta por sí sola: la aprende de ejemplos.

Si fotos de entrenamiento tienen iluminación uniforme y cambia la cámara, el modelo puede aprender el fondo. Prueba estaciones completas fuera del entrenamiento y revisa falsos negativos con técnicos.

Una conexión residual suma una corrección aprendida a la señal: y=F(x)+x. ResNet propuso este enfoque para facilitar optimización de redes profundas (He et al., 2015); no implica que toda tarea necesite cientos de capas.

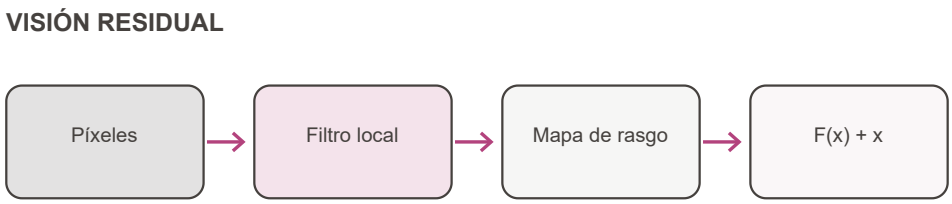


Figura 6.1 · Un filtro recorre regiones y un atajo residual suma una corrección.

CAPÍTULO 7

De la memoria secuencial a los Transformers

> *El orden importa cuando una entrada llega paso a paso.*

Una red recurrente procesa cada posición y actualiza un estado. LSTM y GRU usan compuertas para conservar u olvidar información. Un Transformer usa atención para relacionar posiciones y puede calcular muchas en paralelo durante entrenamiento.

Vaswani y colegas describieron en 2017 un Transformer basado en atención, sin recurrencia ni convoluciones. La atención completa entre n elementos puede crecer aproximadamente como n^2 en memoria y cómputo. El paralelismo tiene un coste.

El orden se incorpora con información posicional. “Gato persigue ratón” no equivale a “ratón persigue gato”.

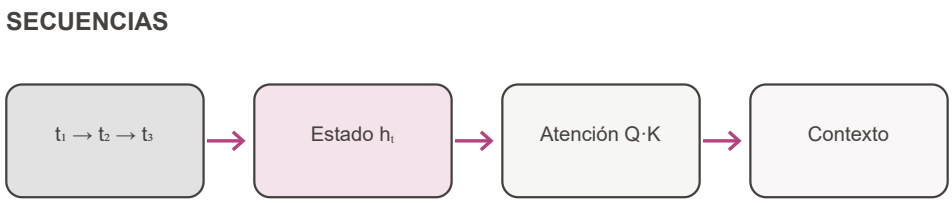


Figura 7.1 · RNN recorre una secuencia; atención conecta posiciones.

RECUERDA

RNN y Transformer modelan orden con mecanismos distintos y costes distintos.

CAPÍTULO 8

Atención: combinar señales según el contexto

> *Cada cabeza pondera relaciones; no es un foco consciente.*

La autoatención proyecta cada posición a consulta, clave y valor. Consulta y claves producen puntuaciones; normalizarlas permite mezclar valores. Varias cabezas repiten esto con proyecciones distintas.

En “El motor se detuvo porque su temperatura subió”, la representación de “su” puede combinar señales de motor y temperatura. Los pesos visibles son solo una parte del cálculo; no prueban causalidad.

Un encoder transforma entradas; un decoder autorregresivo predice usando posiciones anteriores; encoder-decoder combina entrada y generación. Estos nombres no revelan por completo un producto comercial.

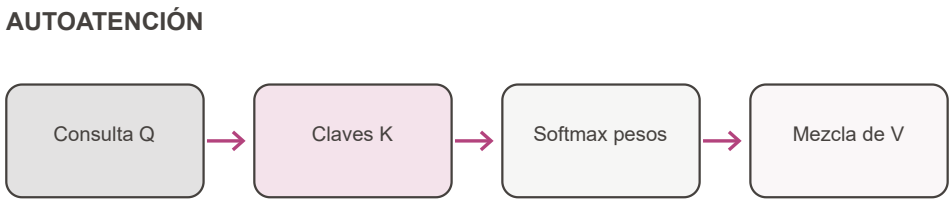


Figura 8.1 · Una consulta pondera claves y combina sus valores.

PARTE III

Escalar y combinar redes

Datos, cómputo, objetivos y modalidades se combinan en sistemas modernos.

CAPÍTULO 9

Preentrenar: aprender regularidades antes de la tarea

> *Datos, objetivo y arquitectura determinan qué aprende el sistema.*

En preentrenamiento el modelo ajusta parámetros sobre grandes colecciones y objetivos generales, como predecir el siguiente token. Aprender regularidades estadísticas no equivale a almacenar hechos verificados.

Escala combina datos, arquitectura, cómputo y receta. Más parámetros con datos deficientes o evaluación pobre pueden elevar costes sin utilidad. Entrenar modelos pequeños permite validar hipótesis de limpieza y objetivo antes de experimentos caros.

Las tendencias de escalamiento describen familias de experimentos; no prometen que toda tarea mejore igual.

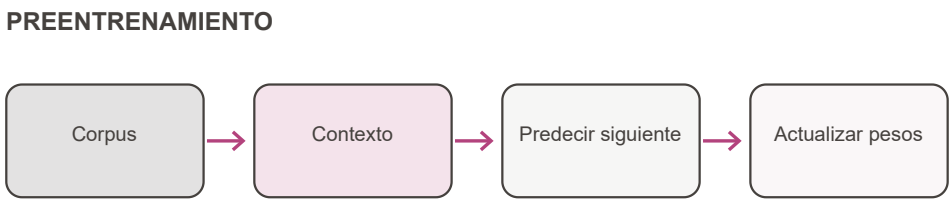


Figura 9.1 · Corpus y objetivo se convierten en parámetros que luego deben evaluarse.

CAPÍTULO 10

Mezcla de expertos: activar rutas especializadas

> *Algunas redes seleccionan subredes para cada entrada.*

Una mezcla de expertos (MoE) contiene expertos y una red de enrutamiento. El router puntúa cada entrada y selecciona algunos expertos. Puede activar una parte de los parámetros, aunque almacenamiento, comunicación y balanceo siguen costando.

El informe de DeepSeek-V3 (diciembre de 2024) declara 671 mil millones de parámetros totales y 37 mil millones activos por token. Es un ejemplo publicado fechado, no descripción universal ni garantía de menor coste.

Si casi todas las entradas van a un experto, aparecen cuellos de botella. Un modelo denso puede ser más sencillo de alojar.

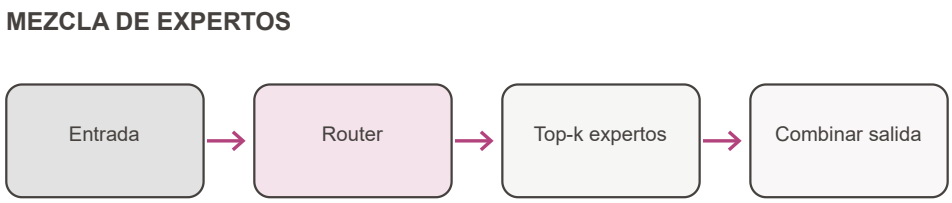


Figura 10.1 · El router dirige una entrada a un subconjunto de expertos.

CAPÍTULO 11

Texto, imagen y audio usan representaciones distintas

> *La modalidad cambia la entrada; no exige una estructura única.*

Vision Transformer divide una imagen en parches proyectados a vectores; el artículo ViT mostró clasificación con secuencias de parches y preentrenamiento. Whisper, caso publicado por OpenAI, usa características log-Mel y arquitectura encoder-decoder Transformer para tareas de voz.

Un sistema multimodal puede proyectar modalidades a tokens y mezclarlas con atención, mantener encoders separados o combinar diseños. Una demostración no revela el pipeline completo.

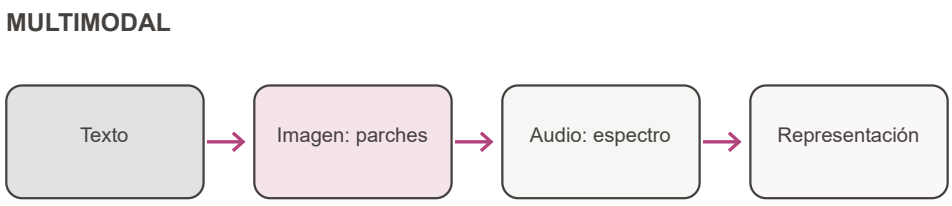


Figura 11.1 · Representaciones de texto, imagen y audio pueden combinarse en módulos compartidos.

ADVERTENCIA

Evalúa texto pequeño, ruido, acentos, oclusiones y sincronización; “multimodal” no garantiza robustez.

PARTE IV

Del modelo al producto

Adaptación, servicio, evaluación y decisión arquitectónica llevan el modelo a uso real.

CAPÍTULO 12

Postentrenamiento: orientar interacción y uso

> *La utilidad cambia después del entrenamiento amplio.*

Ajuste supervisado y preferencias pueden orientar tono, formato y obediencia a instrucciones. No agregan un verificador infalible. Fine-tuning modifica parámetros; recuperación agrega contexto consultado al momento; pueden coexistir y resuelven problemas distintos.

Si el asistente crea órdenes de mantenimiento, valida campos, permisos y confirmación externamente. Un filtro o prompt no reemplaza control de acceso y registro.

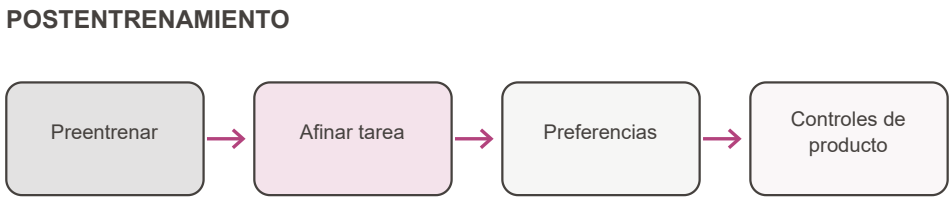


Figura 12.1 · Preentrenamiento, ajuste e integración con controles cumplen objetivos diferentes.

CAPÍTULO 13

Inferencia: responder dentro de un presupuesto

> *En producción importan memoria, latencia, tráfico y calidad.*

Inferencia ejecuta el modelo. Un decoder autorregresivo genera token por token; la caché de claves y valores evita algunos cálculos repetidos y ocupa memoria según contexto y capas.

La experiencia depende de latencia inicial, velocidad, concurrencia, lote y aceleradores. Cuantizar puede reducir memoria; mide calidad y velocidad en hardware real. Establece presupuesto p95, coste por tarea y calidad mínima con tráfico representativo.

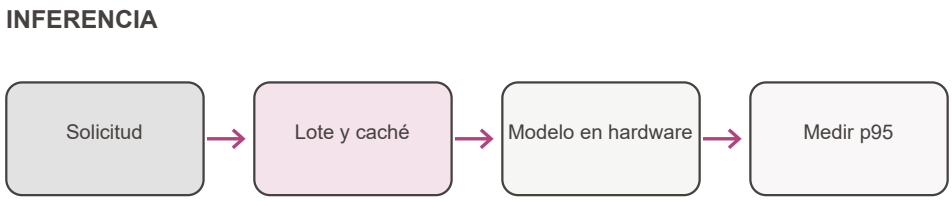


Figura 13.1 · Solicitud, ejecución, controles y medición integran el servicio.

CAPÍTULO 14

Evaluar fallos antes de confiar

> *Mide riesgos concretos, no solo promedios.*

Evalúa tareas representativas, etiquetas revisadas y métricas acordes al impacto. En defectos, recall alto reduce omisiones pero demasiadas alarmas saturan a técnicos. Umbral, capacidad humana y coste de error se deciden conjuntamente.

Para generación mide fidelidad a evidencia, citas, abstención, privacidad, cambios de distribución y daño. Métodos de interpretabilidad muestran proyecciones parciales; el campo no ofrece explicación completa garantizada. No confundas una justificación escrita por el modelo con registro fiel de su proceso.

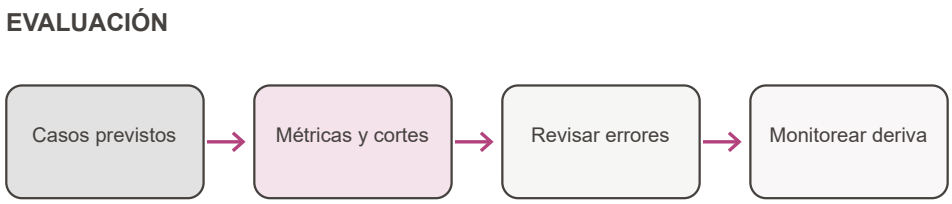


Figura 14.1 · Prioriza evaluación por impacto y frecuencia, y monitorea cambios.

CAPÍTULO 15

Caso completo: elegir red para una empresa de energía

> *La tarea determina la arquitectura; la moda no sustituye requisitos.*

SolAndes, empresa ficticia, mantiene inversores solares. Quiere detectar fallas en telemetría, revisar fotos y consultar manuales. Son tres tareas.

Telemetría: compara línea base tabular y MLP; si la dinámica temporal importa, prueba modelo secuencial. Separa por planta y fecha. **Fotos:** prueba clasificador visual y revisa omisiones por cámara. **Manuales:** búsqueda con fuentes autorizadas, permisos y vigencia; el volumen XI explica fragmentos, embeddings y recuperación.

No se fuerza un modelo único. Los flujos especializados comparten monitoreo y gobernanza. Alertas críticas requieren umbral, evidencia y revisión humana.

1. ¿Qué evento se predice y con cuánta anticipación?
2. ¿Qué datos existen al momento real de decidir?
3. ¿Qué error cuesta más y quién revisa?
4. ¿Cómo se detecta cambio de clima, equipo o cámara?
5. ¿Qué línea base simple se compara?

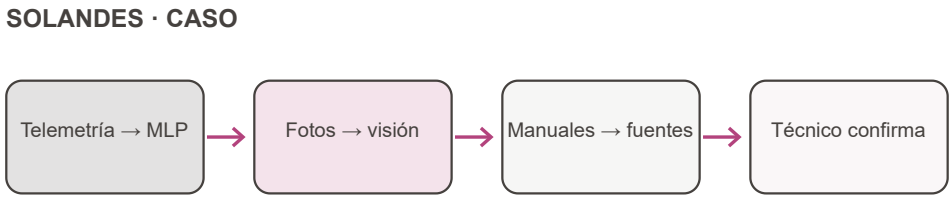


Figura 15.1 · Tres tareas se resuelven con rutas distintas y controles comunes.

DECISIÓN DE ARQUITECTURA

Decisión de arquitectura. Separar los flujos; considerar modelo unificado solo si mejora medida compensa complejidad.

CIERRE

Síntesis

Una red compone operaciones cuyos parámetros se ajustan con un objetivo. La arquitectura incorpora supuestos sobre vecindad, orden, relaciones y cómputo. La evaluación estima si el patrón se sostiene fuera del entrenamiento.

El resultado de producto también depende de datos, recuperación, permisos, hardware, supervisión y operación. Empieza por la tarea, una línea base y una prueba representativa.

REFERENCIA

Glosario

Activación

Función no lineal aplicada a entradas ponderadas.

Atención

Operación que mezcla información de posiciones según puntuaciones.

Backpropagation

Cálculo de gradientes a través de la red.

Capa

Transformación de una representación.

CNN

Red que aplica filtros compartidos sobre vecindades.

Conexión residual

Suma una transformación aprendida a la entrada de un bloque.

Embedding

Representación vectorial aprendida.

Inferencia

Ejecución de un modelo entrenado.

MLP

Red de capas densas y activaciones.

MoE

Arquitectura que enruta entradas a expertos seleccionados.

Parámetro

Valor ajustable del modelo.

Pérdida

Medida del error relativo al objetivo.

Preentrenamiento

Entrenamiento amplio previo a adaptación.

Regularización

Técnicas para limitar sobreajuste.

Sesgo

Término que desplaza una combinación ponderada.

Sobreajuste

Ajuste a particularidades de entrenamiento con mala generalización.

Tasa de aprendizaje

Tamaño del paso del optimizador.

Token

Unidad discreta de texto; véase volumen XI.

REFERENCIA

Fuentes

1. Vaswani et al.. Attention Is All You Need. https://arxiv.org/abs/1706.03762. Consulta: 2026-10-18.
2. He et al.. Deep Residual Learning for Image Recognition. https://arxiv.org/abs/1512.03385. Consulta: 2026-10-18.
3. Dosovitskiy et al.. An Image is Worth 16x16 Words. https://arxiv.org/abs/2010.11929. Consulta: 2026-10-18.
4. DeepSeek-AI. DeepSeek-V3 Technical Report. https://arxiv.org/abs/2412.19437. Consulta: 2026-10-18.
5. OpenAI. Introducing Whisper. https://openai.com/index/whisper/. Consulta: 2026-10-18.
6. OpenAI. GPT-4 Technical Report. https://arxiv.org/abs/2303.08774. Consulta: 2026-10-18.
7. Ho et al.. Denoising Diffusion Probabilistic Models. https://arxiv.org/abs/2006.11239. Consulta: 2026-10-18.
8. Peebles y Xie. Scalable Diffusion Models with Transformers. https://arxiv.org/abs/2212.09748. Consulta: 2026-10-18.
9. OpenAI. Extracting concepts from GPT-4. https://openai.com/index/extracting-concepts-from-gpt-4/. Consulta: 2026-10-18.

COLOFÓN

Sobre esta colección

La red que aprende · Araña · Las conexiones aprenden patrones; cada arquitectura incorpora decisiones y límites distintos · 2026.

#	Título	Animal	Ángulo
I	Agentes de IA: De la idea a la producción	Pulpo	Inteligencia distribuida
II	Construyendo con Agentes de IA	Hormiga	Enjambre emergente
III	Agentes de IA: Una guía ilustrada	Cuervo	Uso inteligente de herramientas
IV	Patrones Arquitectónicos para Sistemas Multiagente	Abeja	Patrones de coordinación probados
V	Agentes de IA con MCP	Delfín	Comunicación y protocolo
VI	Agentes de IA en Acción	Zorro	Acción inteligente y adaptativa
VII	Agentes de IA en la práctica	Castor	Ingeniería orientada a producción
VIII	El Segundo Cerebro Corporativo	Ardilla	Conocimiento almacenado y recuperable
IX	La Federación de Cerebros	Suricata	Vigilancia distribuida
X	La Máquina de Predecir	Cachalote	Percepción construida desde señales y patrones
XI	Del texto al contexto	Murciélago	Encontrar señales parecidas sin confundirlas con hechos
XII	**La red que aprende**	**Araña**	**Las conexiones aprenden patrones; cada arquitectura incorpora decisiones y límites distintos**
—	El Castor y el Plano — Spec-Driven Development con agentes	Castor	Construir siguiendo un plano vivo