Aprender de los datos

Machine Learning para logística, comercial, finanzas y operaciones



ESCRITO E ILUSTRADO POR

Biblioteca de Agentes de IA

XIII
MAPACHE

Aprender de los datos

Machine Learning para logística, comercial, finanzas y operaciones

Biblioteca de Agentes de IA · XIII
2026

Sobre la portada

El mapache explora con atención, reconoce marcas y manipula objetos con sus patas.

Su máscara y cola anillada hacen de él un explorador reconocible entre señales distintas: una imagen para introducir la búsqueda de patrones en datos de empresa.

Los datos reales no son objetos que el animal comprenda; el aprendizaje depende de etiquetas, funciones, objetivos matemáticos y pruebas. El mapache no es una red neuronal ni un modelo estadístico, y su conducta no explica cómo se entrena un algoritmo. La metáfora termina ahí.

Prefacio

¿Cómo usar datos del ERP para tomar mejores decisiones sin confundir una predicción con una orden?

Este libro acompaña a responsables de logística, comercial, finanzas y operaciones desde la pregunta hasta la operación del modelo. Recorre fundamentos de ML, construcción de tablas, métricas y casos por área; después aborda librerías Python, ejecución local, servicios y APIs, integración con agentes y seguimiento en producción.

Los casos y cifras empresariales son ficticios y se identifican como tales. Las recomendaciones técnicas separan principios estables de documentación de herramientas consultada en octubre de 2026. El volumen XII, «La red que aprende», es la lectura complementaria para profundizar en redes neuronales.

Cómo leer este libro

Lee las cuatro partes en orden si partes de cero. Quien ya conoce ML puede comenzar por los capítulos 11–15 y volver a los capítulos de evaluación al definir un caso. La última parte incluye arquitectura y un capstone integrador.

Las cajas CASO describen escenarios ficticios; las ADVERTENCIAS señalan errores de diseño; RECUERDA condensa la decisión práctica. En los ejemplos, las puntuaciones son estimaciones, no hechos observados.

Índice

PARTE I · ENTENDER EL APRENDIZAJE

1 Qué significa aprender de datos

Cómo se aplica · Qué revisar antes de avanzar

2 De la pregunta empresarial a una etiqueta

Cómo se aplica · Qué revisar antes de avanzar

3 La tabla que el modelo puede aprender

Cómo se aplica · Qué revisar antes de avanzar

4 Fuga de información y calidad

Cómo se aplica · Qué revisar antes de avanzar

5 Supervisado, no supervisado y por refuerzo

Cómo se aplica · Qué revisar antes de avanzar

PARTE II · PREPARAR Y MEDIR

6 Baselines, métricas y coste del error

Cómo se aplica · Qué revisar antes de avanzar

7 Predecir cantidades con regresión

Cómo se aplica · Qué revisar antes de avanzar

8 Clasificar sin esconder la incertidumbre

Cómo se aplica · Qué revisar antes de avanzar

9 Grupos, anomalías y exploración

Cómo se aplica · Qué revisar antes de avanzar

10 Pronosticar a través del tiempo

Cómo se aplica · Qué revisar antes de avanzar

PARTE III · RESOLVER PROBLEMAS DEL NEGOCIO

11 Logística: demanda, retrasos y capacidad

Cómo se aplica · Qué revisar antes de avanzar

12 Comercial: propensión, churn y recomendación

Cómo se aplica · Qué revisar antes de avanzar

13 Finanzas: flujo, riesgo y anomalías

Cómo se aplica · Qué revisar antes de avanzar

14 Operaciones: mantenimiento, calidad y energía

Cómo se aplica · Qué revisar antes de avanzar

15 Casos por rubro, mismo método

Cómo se aplica · Qué revisar antes de avanzar

PARTE IV · LLEVAR MODELOS A PRODUCCIÓN

16 Del ERP al pipeline de datos

Cómo se aplica · Qué revisar antes de avanzar

17 Librerías y entorno Python

Cómo se aplica · Qué revisar antes de avanzar

18 Misma máquina, servidor o API

Cómo se aplica · Qué revisar antes de avanzar

19 Diseñar una API de predicción

Cómo se aplica · Qué revisar antes de avanzar

20 Modelo, reglas, procesos y agentes

Cómo se aplica · Qué revisar antes de avanzar

21 Monitorear, renovar y cerrar el ciclo

Cómo se aplica · Qué revisar antes de avanzar

CIERRE

Glosario

Fuentes

Colofón

PARTE I

Entender el aprendizaje

Separar los conceptos y definir la señal que una decisión necesita.

CAPÍTULO 1

Qué significa aprender de datos

> *Un modelo aprende una regularidad útil a partir de ejemplos.*

Machine Learning (ML) construye funciones que asignan entradas a salidas y ajusta sus parámetros con datos. En una distribuidora, una regla puede marcar como tardío todo pedido con más de 48 horas. Un modelo puede estimar la probabilidad de retraso combinando ruta, hora, clima disponible, proveedor y congestión histórica. Ninguno conoce el futuro: ambos producen señales para una decisión.

Cómo se aplica

IA es el campo amplio; ML es una familia de métodos que ajustan modelos con datos; aprendizaje profundo usa redes neuronales; una regla ejecuta condiciones escritas; un agente coordina pasos y herramientas. El volumen XII estudia redes neuronales en detalle. Para muchas tablas empresariales, árboles potenciados y regresión son referencias fuertes y más sencillas de operar.

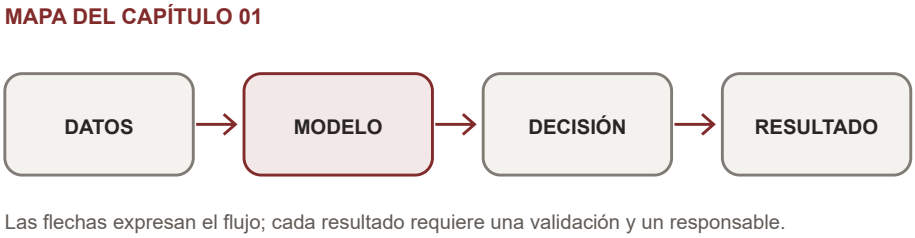


Figura 1.1 · Qué significa aprender de datos: representación del flujo o decisión que explica este capítulo.

CASO

La analogía del mapache que inspecciona objetos ayuda a pensar en observar, comparar y agrupar. El mapache no optimiza una pérdida ni estima incertidumbre. En el sistema real, la conducta sale de los datos, el objetivo, el algoritmo y el contexto de uso.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

La pregunta correcta no es “¿puede usarse IA?”, sino “¿qué decisión mejora, con qué evidencia y qué coste tiene equivocarse?”.

CAPÍTULO 2

De la pregunta empresarial a una etiqueta

> *Cada modelo necesita un objetivo definido en el tiempo.*

“Mejorar ventas” no es todavía un problema de ML. Una pregunta operable sería: para cada cliente activo el lunes, estimar si comprará durante los siguientes 30 días. La etiqueta es ese resultado futuro; las características son lo que se conocía el lunes. Cambiar el horizonte o la unidad (pedido, cliente, tienda) cambia el problema y la métrica.

Cómo se aplica

Antes de entrenar acuerda quién usará la salida, cuándo, qué acción puede tomar y cuál es la línea base. Si logística necesita priorizar diez pedidos al día, ordenar correctamente el grupo de alto riesgo puede importar más que el error promedio. El contrato del problema evita modelos elegantes sin usuario ni decisión.

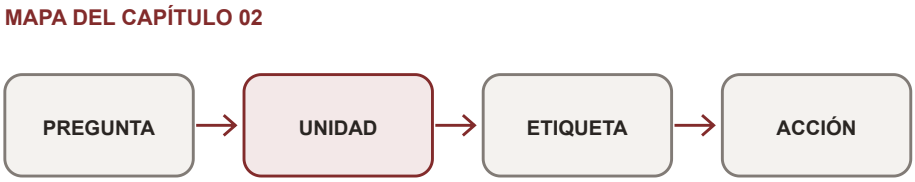


Figura 2.1 · De la pregunta empresarial a una etiqueta: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio: una cadena quiere reducir quiebres. Unidad: SKU-tienda-semana. Objetivo: predecir unidades demandadas para la próxima semana. Decisión: sugerir una reposición, sujeta a stock, mínimo de compra y aprobación del planificador.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Una definición compacta une unidad de predicción, instante, horizonte, etiqueta, usuario, acción y métrica.

CAPÍTULO 3

La tabla que el modelo puede aprender

> *La tabla de entrenamiento debe reflejar el momento de decisión.*

Cada fila representa una predicción posible. Las columnas contienen atributos disponibles antes del resultado. Una tabla de pedidos puede tener fecha de creación, ruta, transportista, día de semana y backlog. El campo “fecha de entrega real” describe el resultado, por lo que sirve para crear la etiqueta, no como entrada.

Cómo se aplica

ERP, CRM, WMS, TMS y archivos suelen tener claves distintas, zonas horarias y estados corregidos retroactivamente. Conserva identificador de entidad, timestamp de corte, procedencia y versión de transformaciones. Agrega al nivel de la decisión: unir ventas por cliente cuando la unidad es pedido puede duplicar filas y distorsionar el aprendizaje.

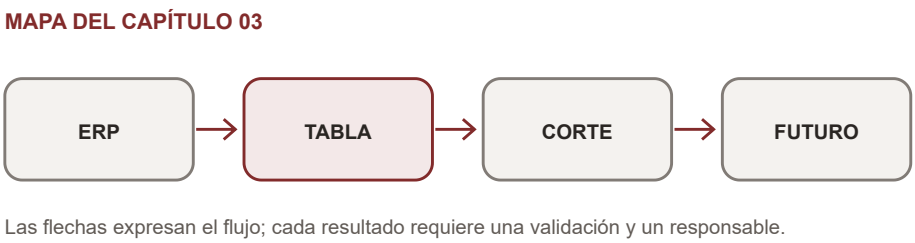


Figura 3.1 · La tabla que el modelo puede aprender: representación del flujo o decisión que explica este capítulo.

CASO

Ejemplo reproducible conceptual: una fila “cliente × fecha de corte” agrega compras de los 90 días anteriores y luego observa compra en los 30 días siguientes. Las columnas del futuro se mantienen fuera de la matriz X.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

El grano de la tabla define qué significa una observación; una unión equivocada puede aparentar mucho volumen y destruir la validez.

CAPÍTULO 4

Fuga de información y calidad

> *Un modelo puede parecer excelente porque vio pistas del futuro.*

Fuga (data leakage) ocurre cuando una característica incluye información que no existiría al puntuar. Para predecir impago, “días en cobranza” calculado después del vencimiento filtra el resultado. Separar entrenamiento y prueba al azar no corrige una fuga temporal. También importa detectar duplicados de una misma entidad a ambos lados del corte.

Cómo se aplica

Documenta nulos, rangos imposibles, cambios de código, devoluciones, datos tardíos y revisiones manuales. La imputación y codificación se ajustan solo con el conjunto de entrenamiento dentro de un pipeline. Las fechas deben dividirse cronológicamente cuando el uso futuro es el propósito.

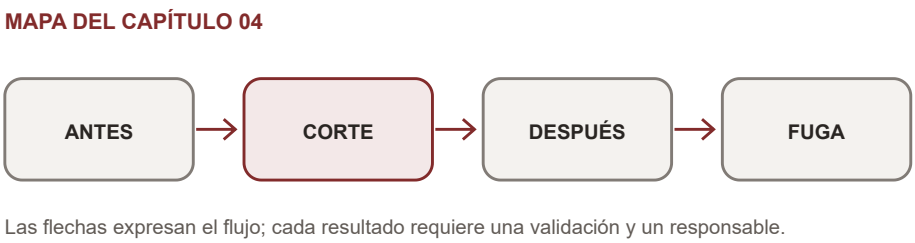


Figura 4.1 · Fuga de información y calidad: representación del flujo o decisión que explica este capítulo.

CASO

Ejercicio del libro: intenta predecir demoras con la fecha de entrega real. La métrica se disparará; al retirar el campo, mide el caso auténtico. La diferencia muestra cuánto valía la filtración, no cuánto aprendió el sistema.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Pregunta en cada columna: ¿estaba disponible exactamente a la hora en que se habría producido esta predicción?

CAPÍTULO 5

Supervisado, no supervisado y por refuerzo

> *El tipo de señal disponible orienta la familia de aprendizaje.*

En supervisado tenemos ejemplos con etiqueta: venta, retraso o demanda observada. En no supervisado no existe esa respuesta explícita; agrupamos comportamientos o detectamos rarezas para investigar. En aprendizaje por refuerzo un agente aprende mediante acciones, estados y recompensas, con retos de exploración y seguridad. Series temporales añaden estructura de orden y horizonte.

Cómo se aplica

Un clúster no es una verdad natural: depende de variables, distancia y escala. Una anomalía no necesariamente es fraude. El refuerzo no es "dar puntos a cualquier modelo"; se requiere definir consecuencias, restricciones y un entorno de evaluación. Para pronosticar conviene comparar contra un baseline temporal ingenuo y respetar cortes por fecha.



Figura 5.1 · Supervisado, no supervisado y por refuerzo: representación del flujo o decisión que explica este capítulo.

CASO

Matriz mental: ¿hay resultado histórico fiable? Si sí, supervisado. ¿Buscas estructura para análisis? No supervisado. ¿la decisión cambia el entorno y recibimos recompensa? Considera refuerzo, generalmente en problemas con simulador o control acotado.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

No elijas algoritmo antes de confirmar qué señal de aprendizaje existe.

PARTE II

Preparar y medir

Construir tablas válidas y evaluar el valor con costes reales.

CAPÍTULO 6

Baselines, métricas y coste del error

> *Una métrica técnica debe traducirse a consecuencias de negocio.*

Empieza con una regla sencilla: promedio estacional, último valor, regresión lineal o política actual. Para clasificación, exactitud puede engañar si solo 1% de facturas son fraudulentas. Precisión responde cuántas alertas fueron relevantes; recall, cuántos casos relevantes se encontraron. MAE expresa error medio en unidades; RMSE penaliza más los errores grandes.

Cómo se aplica

El umbral depende del coste. Un falso positivo puede enviar un camión a revisión; un falso negativo puede dejar una tienda sin producto. La calibración pregunta si los casos estimados a 20% ocurren cerca de 20% en grupos comparables. Compara también tiempo humano, coste de inventario, latencia y carga de revisión.

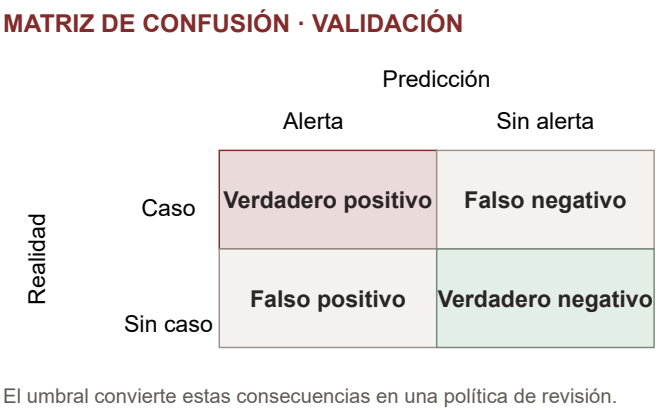


Figura 6.1 · Baselines, métricas y coste del error: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio de fraude: revisar una alerta cuesta S/ 8; una pérdida no detectada cuesta mucho más. El equipo limita alertas a la capacidad diaria y selecciona umbral con validación temporal y revisión de segmentos. No atribuye ahorro causal al modelo sin experimento.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

La mejor métrica es la que ayuda a elegir una acción bajo restricciones reales.

CAPÍTULO 7

Predecir cantidades con regresión

> *La regresión produce una cantidad y necesita unidades interpretables.*

Demanda, importe de reparación y tiempo de llegada son cantidades. Un modelo de regresión estima una función desde atributos a un valor. Para inventario, no basta con MAE: subestimar demanda suele ser más costoso que sobreestimarla. Cuantiles o intervalos pueden describir escenarios, aunque requieren validación de cobertura.

Cómo se aplica

Los extremos, ceros y cambios de régimen exigen análisis. Regresión lineal ofrece una referencia explicable; Random Forest y gradient boosting capturan relaciones no lineales en tablas. La predicción puntual no es una orden de compra: la cantidad sugerida depende también de stock disponible, plazo, lote mínimo y política.

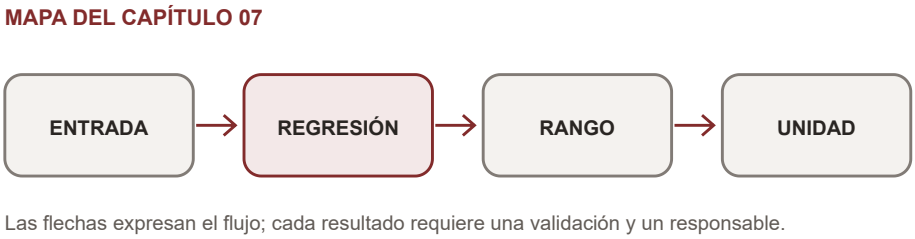


Figura 7.1 · Predecir cantidades con regresión: representación del flujo o decisión que explica este capítulo.

CASO

Ejemplo: pronóstico central 42 unidades, rango operativo 31–58. Con plazo de reposición de una semana y stock 20, la recomendación depende del nivel de servicio y coste de quiebre acordados.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Predice la variable correcta y conserva su unidad: soles, horas, unidades o días.

CAPÍTULO 8

Clasificar sin esconder la incertidumbre

> *Una clase es una decisión construida sobre una puntuación y un umbral.*

Un clasificador puede devolver una probabilidad estimada de cancelación. El umbral 0.5 no es ley. Si una llamada cuesta menos que una cancelación, el umbral puede reducirse; si saturar al equipo comercial cuesta mucho, puede subir. El puntaje prioriza revisión, no demuestra intención individual.

Cómo se aplica

Revisa precision-recall, matriz de confusión, calibración, estabilidad y resultados por grupos autorizados. En crédito y empleo, la validez técnica no sustituye gobernanza, revisión legal ni evaluación de impacto. Explica a usuarios qué significa el puntaje y qué no significa.

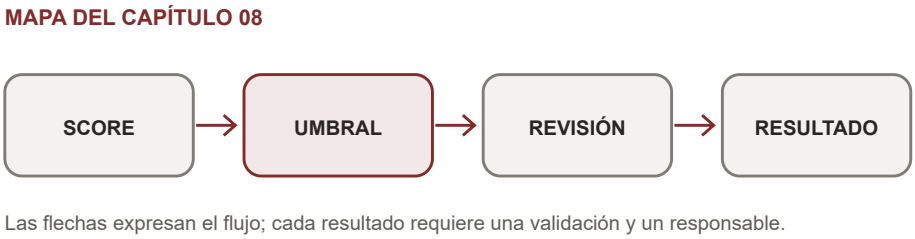


Figura 8.1 · Clasificar sin esconder la incertidumbre: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio de churn: el equipo de retención solo contacta a 300 cuentas de 10 000. Selecciona top-k dentro de la capacidad, prueba dos políticas y mide retención incremental frente a control. Un ranking alto no prueba que el contacto vaya a persuadir.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

La probabilidad ordena evidencia; el umbral incorpora costes, capacidad y política.

CAPÍTULO 9

Grupos, anomalías y exploración

> *El aprendizaje sin etiquetas propone preguntas para investigar.*

Clustering puede revelar grupos de compra, rutas o consumo energético. Escala y representación de variables importan: una columna de moneda con números altos puede dominar una distancia. PCA ayuda a visualizar variación, pero comprimir dimensiones pierde información. Isolation Forest y métodos robustos pueden priorizar registros inusuales.

Cómo se aplica

Valida grupos con expertos y utilidad de decisión. Un clúster puede separar tiendas grandes de pequeñas por volumen, algo obvio pero útil para segmentar baselines. Una anomalía puede ser nueva campaña, captura defectuosa, fraude o cambio legítimo. La revisión humana convierte una lista en aprendizaje operativo.

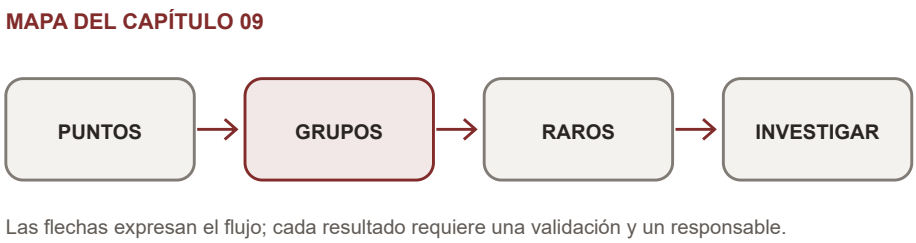


Figura 9.1 · Grupos, anomalías y exploración: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio: mantenimiento agrupa vibración y temperatura por tipo de máquina; investiga puntos alejados. Solo tras inspecciones y registro de resultados se crea una etiqueta confiable para un futuro modelo supervisado.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Una alerta de anomalía significa “revisar este patrón”; no significa “encontramos una causa”.

CAPÍTULO 10

Pronosticar a través del tiempo

> *Los datos de calendario obligan a validar siguiendo el reloj.*

Demanda y flujo de caja tienen tendencia, estacionalidad, festivos, promociones y cambios estructurales. Una partición aleatoria mezcla pasado y futuro y mide una situación que no se desplegará. Usa cortes rodantes: entrena hasta T, evalúa en T+1 y repite para varias ventanas.

Cómo se aplica

Compara contra último valor, mismo día de semana o misma estación. Reentrena según coste y estabilidad, no por ritual diario. Las variables futuras (precio planeado, calendario) solo se usan si realmente se conocen al hacer el pronóstico. Agrega intervalos y registra versiones de datos.

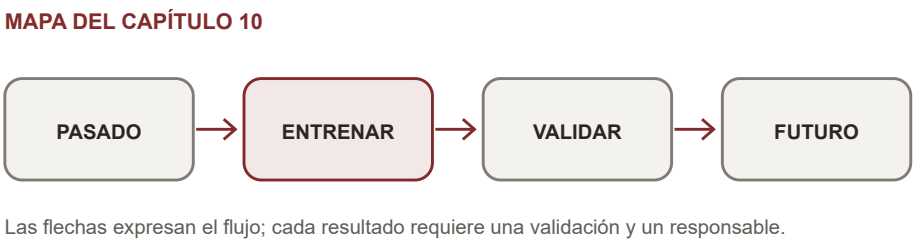


Figura 10.1 · Pronosticar a través del tiempo: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio: pronóstico semanal de 26 semanas para tesorería. Finanzas evalúa error por horizonte y escenario; no presenta la suma como caja garantizada.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Una evaluación temporal representa la pregunta “qué habría sabido el modelo en aquel momento”.

PARTE III

Resolver problemas del negocio

Llevar métodos apropiados a áreas y rubros distintos.

CAPÍTULO 11

Logística: demanda, retrasos y capacidad

> *ML estima incertidumbre logística; la optimización decide asignaciones factibles.*

Usos posibles: demanda por tienda y SKU, retraso de entrega, tiempo de preparación, probabilidad de ruptura, daños y mantenimiento de flota. La predicción ETA usa lo disponible antes del tramo. Mide error por ruta y horizonte; comunica rangos cuando la precisión cambia por zona o tráfico.

Cómo se aplica

Ruteo, consolidación de carga y asignación de flota suelen ser problemas de optimización combinatoria. ML puede alimentar sus parámetros —tiempos probables o demanda—, pero no sustituye restricciones, ventanas, capacidad ni seguridad vial. Predicción y optimización se conectan mediante un contrato explícito.

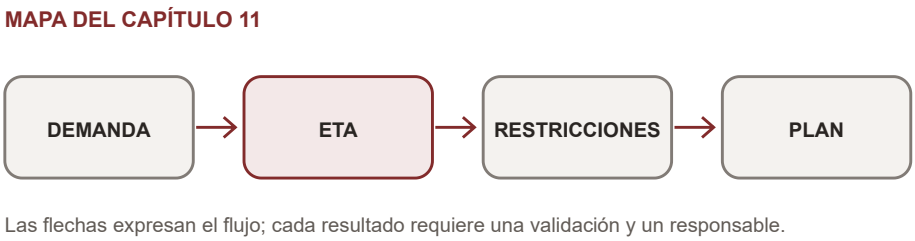


Figura 11.1 · Logística: demanda, retrasos y capacidad: representación del flujo o decisión que explica este capítulo.

CASO

Flujo: WMS/TMS → datos históricos de salida y llegada → modelo estima retraso → optimizador recalcula prioridades factibles → operador confirma → resultado vuelve con timestamp y causa. Caso ficticio; no implica navegación autónoma.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

No llames “ruta aprendida” a una recomendación que en realidad requiere optimización y restricciones.

CAPÍTULO 12

Comercial: propensión, churn y recomendación

> *La predicción de compra no es el efecto de una campaña.*

Modelos pueden ordenar leads, detectar riesgo de abandono, pronosticar ventas o sugerir productos compatibles. La propensión estima comportamiento bajo una política histórica; no cuánto cambiará ese comportamiento al contactar. Para estimar efecto incremental se requieren experimentos, diseños causales y supuestos documentados.

Cómo se aplica

Atención al sesgo de selección: solo llamamos a ciertos clientes y solo conocemos algunas respuestas. Evita variables sensibles sin base y gobernanza. Los equipos necesitan explicación útil, horizonte, fecha y acción permitida, no una lista misteriosa de “clientes malos”.

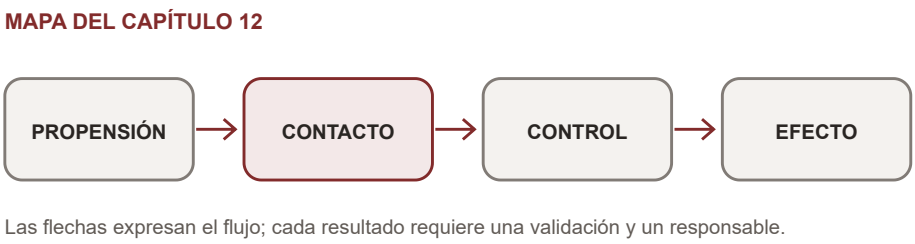


Figura 12.1 · Comercial: propensión, churn y recomendación: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio: una empresa de equipos industriales prioriza cuentas con necesidad de repuesto. Se asigna grupo de tratamiento y control por segmento para medir margen incremental, no solo tasa de apertura.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Propensión predice quién podría comprar; causalidad pregunta a quién convence la acción.

CAPÍTULO 13

Finanzas: flujo, riesgo y anomalías

> *La salida del modelo apoya controles financieros; no los reemplaza.*

Pronosticar cobranza ayuda a escenarios de caja; clasificación prioriza facturas para validación; anomalías destacan transacciones atípicas. Separar detección de fraude de decisión final: reglas de cumplimiento, listas y auditoría tienen requisitos propios. Un modelo puede cambiar cuando se modifica política de registro o canal de pago.

Cómo se aplica

Backtest temporal, calibración, falsos positivos por proveedor, trazabilidad de datos y segregación de funciones son esenciales. En decisiones reguladas deben intervenir responsables y controles vigentes. Ninguna puntuación elimina el deber de explicación, revisión y registro.

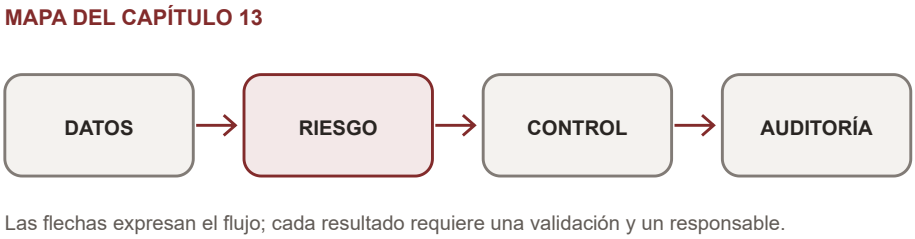


Figura 13.1 · Finanzas: flujo, riesgo y anomalías: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio: tesorería recibe bandas de caja base/alto/bajo y lista de facturas con motivos observables. El sistema conserva versión del modelo, fecha de corte, fuentes y ajustes manuales.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

En finanzas, cada recomendación debe poder reconstruirse y cuestionarse.

CAPÍTULO 14

Operaciones: mantenimiento, calidad y energía

> *Sensores, órdenes y turnos describen procesos con contexto.*

ML puede estimar riesgo de falla, defectos, consumo o duración de ciclo. En mantenimiento predictivo, una alarma útil llega antes de la parada y con suficiente tiempo para actuar. Etiquetas como “falla” pueden ser ambiguas; inspecciones y órdenes cerradas aportan evidencia, pero su calidad varía.

Cómo se aplica

Evita entrenar solo con máquinas que recibieron inspección: el historial refleja qué se decidió observar. Incluye régimen, carga, mantenimiento y ambiente. Evalúa por activo y tiempo; protege procesos críticos con umbrales conservadores y modo de observación antes de automatizar.

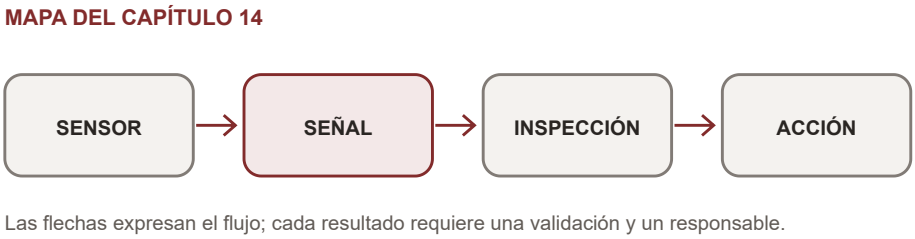


Figura 14.1 · Operaciones: mantenimiento, calidad y energía: representación del flujo o decisión que explica este capítulo.

CASO

Caso ficticio de manufactura: un score prioriza inspecciones diarias; supervisor registra hallazgo, pieza y acción. El piloto compara paradas, falsas alarmas y horas de inspección con línea base.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

El sensor ve señales; el proceso aporta contexto, mecanismo de intervención y consecuencias.

CAPÍTULO 15

Casos por rubro, mismo método

> *El dominio cambia la decisión, los datos y el coste de error.*

Retail: demanda y surtido. Manufactura: calidad y paradas. Agricultura: rendimiento condicionado por campaña, clima y suelo. Transporte: ETA y capacidad. Banca y seguros: riesgo con requisitos elevados de privacidad, explicabilidad y gobierno. Salud y servicios públicos requieren evaluación cuidadosa de impacto y responsables.

Cómo se aplica

No traslades una métrica o umbral de una empresa a otra. Define representante del dominio, responsable de datos, operador, afectado por la decisión y equipo técnico. Segmenta pruebas por temporada, geografía, equipo y canal cuando representen cambios materiales.

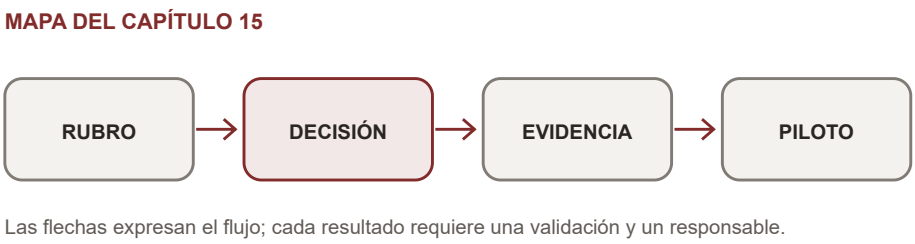


Figura 15.1 · Casos por rubro, mismo método: representación del flujo o decisión que explica este capítulo.

CASO

Plantilla de caso: decisión actual; unidad; datos permitidos; etiqueta y horizonte; baseline; coste de error; evaluación temporal; piloto; mecanismo de revisión; condición de retiro.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

La técnica se puede reutilizar; la evidencia y la política deben validarse en cada contexto.

PARTE IV

Llevar modelos a producción

Conectar ERP, Python, API, agentes y monitoreo con controles.

CAPÍTULO 16

Del ERP al pipeline de datos

> *El modelo aprende de vistas controladas, no de una conexión improvisada a producción.*

Una arquitectura común: ERP/CRM/WMS → extracción incremental o eventos → área de aterrizaje → validación y transformación → almacén de características/versiones → entrenamiento → registro de modelo → servicio de inferencia → consumidor. Separa permisos de lectura del proceso de escritura empresarial.

Cómo se aplica

Batch es adecuado para pronósticos diarios; streaming reduce retraso cuando la señal y la acción lo justifican. Conserva idempotencia, deduplicación, timestamps y linaje. Evita consultar tablas transaccionales pesadas a cada petición. Contratos de datos hacen explícito tipo, unidad, nulos y semántica.

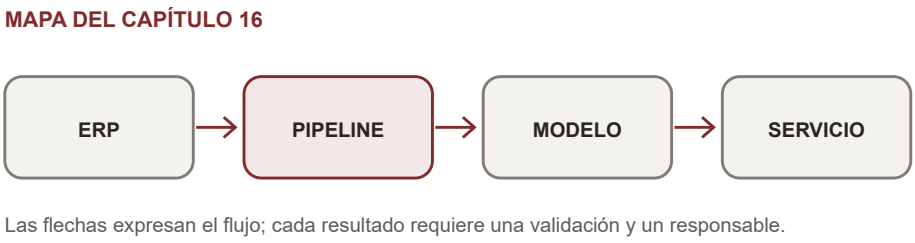


Figura 16.1 · Del ERP al pipeline de datos: representación del flujo o decisión que explica este capítulo.

CASO

Patrón inicial: réplica o vista de lectura con cuenta mínima; exportación diaria anonimizada para probar valor; aprobación de seguridad antes de mover datos sensibles. El modelo devuelve propuesta; la aplicación registra la acción en el flujo autorizado del ERP.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Acopla el modelo a una interfaz estable y gobernada, no a cada tabla interna del ERP.

CAPÍTULO 17

Librerías y entorno Python

> *La librería se elige por tarea, datos y soporte operativo.*

pandas o Polars preparan tablas; scikit-learn aporta pipelines, transformaciones y muchos algoritmos; XGBoost, LightGBM y CatBoost ofrecen boosting tabular; statsmodels ayuda a modelado estadístico y series; PyTorch sirve para redes neuronales; MLflow registra corridas y artefactos. La librería no resuelve fuga, calidad ni gobierno.

Cómo se aplica

Instala en entorno virtual reproducible, fija versiones, conserva lock/requirements, verifica compatibilidad de Python, sistema operativo y CPU/GPU. En un servidor aislado prepara paquetes aprobados y repositorio interno; no instales dependencias como administrador sin revisión. Comienza en CPU si la tarea lo permite.

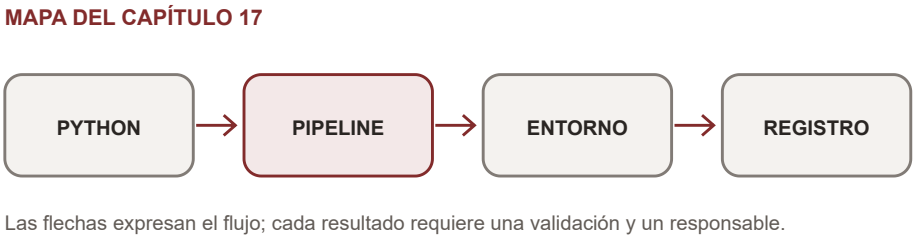


Figura 17.1 · Librerías y entorno Python: representación del flujo o decisión que explica este capítulo.

PYTHON

```
import pandas as pd
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.ensemble import HistGradientBoostingRegressor
from sklearn.metrics import mean_absolute_error

datos = pd.read_csv("demanda_sintetica.csv", parse_dates=["semana"])
datos = datos.sort_values("semana")
corte = datos["semana"].max() - pd.Timedelta(weeks=8)
train, test = datos[datos.semana < corte], datos[datos.semana >=
corte]
cols = ["dias_semana", "precio", "promo", "stock_inicio"]
X_train, y_train = train[cols], train["unidades"]
X_test, y_test = test[cols], test["unidades"]
numericas = ["dias_semana", "precio", "stock_inicio"]
categoricas = ["promo"]
prep = ColumnTransformer([
    ("num", make_pipeline(SimpleImputer(), StandardScaler()),
numericas),
    ("cat", make_pipeline(SimpleImputer(strategy="most_frequent"),
                          OneHotEncoder(handle_unknown="ignore")),
categoricas),
])
modelo = make_pipeline(prep, HistGradientBoostingRegressor())
modelo.fit(X_train, y_train)
print("MAE:", mean_absolute_error(y_test, modelo.predict(X_test)))
```

Este patrón es una plantilla didáctica; el conjunto sintético no contiene stockouts ni festivos. Antes de producción se requieren validación rodante, baseline, análisis de error por SKU y control de fuga. El pipeline se guarda junto al modelo.

CASO

Ejemplo de pipeline scikit-learn: ColumnTransformer → imputación/codificación → modelo → validación. Exporta el pipeline completo para que transformación y predicción usen la misma lógica. El snippet del capítulo documenta train/test temporal y métrica.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

El entorno de producción forma parte del modelo reproducible.

CAPÍTULO 18

Misma máquina, servidor o API

> *La ubicación del cálculo cambia latencia, privacidad y mantenimiento.*

Un modelo tabular puede correr en la misma máquina que analiza un archivo. Para un equipo, un servicio interno puede centralizar versión, recursos y permisos. Una API permite que ERP, proceso o agente soliciten predicciones. Evalúa CPU/GPU, volumen, concurrencia, disponibilidad, datos sensibles, conectividad y operación.

Cómo se aplica

Local no significa automáticamente seguro; API no significa automáticamente nube pública. On-prem puede limitar salida de datos, pero requiere parches, despliegue, monitorización y continuidad. Inferencia por lotes es eficiente para grandes tablas; online para decisiones con baja latencia.

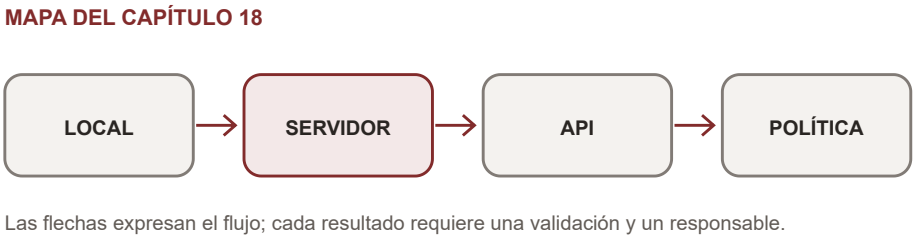


Figura 18.1 · Misma máquina, servidor o API: representación del flujo o decisión que explica este capítulo.

CASO

Diagrama compara script local, servicio interno y API gestionada. La opción del ejemplo envía solo features autorizadas al endpoint privado; almacena ID de solicitud, versión y resultado, no secretos ni datos innecesarios.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Elige la topología que el equipo pueda proteger, observar y mantener.

CAPÍTULO 19

Diseñar una API de predicción

> *El contrato API convierte el modelo en una capacidad consumible.*

Una petición debe versionar esquema e incluir identificador idempotente si hay reintentos. La respuesta incluye puntuación, unidad o clase, versión del modelo, timestamp y advertencias relevantes. Define autenticación, límites, timeout, códigos de error, validación y registro. No expongas detalles internos ni información de otras entidades.

Cómo se aplica

FastAPI es una opción de Python para construir endpoints con validación de tipos y documentación OpenAPI. Antes de desplegar, añade autenticación institucional, TLS, autorización, auditoría, observabilidad, análisis de dependencias y pruebas de contrato. El endpoint no debe ejecutar SQL arbitrario recibido del cliente.

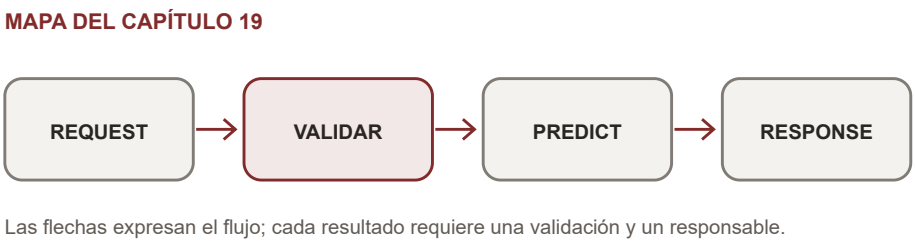


Figura 19.1 · Diseñar una API de predicción: representación del flujo o decisión que explica este capítulo.

PYTHON

```python
from fastapi import FastAPI
from pydantic import BaseModel, Field

app = FastAPI(title="Predicción de demanda", version="1")

class Entrada(BaseModel):
    sku: str
    precio: float = Field(ge=0)
    stock_inicio: int = Field(ge=0)

class Salida(BaseModel):
    unidades_estimadas: float
    model_version: str

@app.post("/v1/predict", response_model=Salida)
def predict(x: Entrada):
    # En producción: features autorizadas, artefacto cargado al
iniciar,
    # autenticación institucional, logs sin datos sensibles y
límites.
    fila = [[x.precio, x.stock_inicio]]
    y = float(model.predict(fila)[0])
    return Salida(unidades_estimadas=max(0, y), model_version="2026-
10")
```

El ejemplo ilustra el contrato; presupone un modelo cargado llamado `model`. No es una configuración de seguridad lista para desplegar.

CASO

Ejemplo de respuesta: {"prediction": 0.73, "label": "revisar", "model_version": "2026-10", "as_of": "..."}. 0.73 es probabilidad estimada bajo validación; no es certeza.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los

resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

La API debe explicar qué devuelve, de qué versión y bajo qué supuestos.

CAPÍTULO 20

Modelo, reglas, procesos y agentes

> *El modelo aporta una señal; el proceso fija responsabilidades y permisos.*

Un flujo seguro: evento de pedido → reglas deterministas de elegibilidad → modelo estima riesgo → proceso ordena casos → agente resume evidencias autorizadas y prepara borrador → persona confirma → aplicación registra acción. Un agente puede llamar al endpoint como herramienta, pero no mejora mágicamente la calidad estadística.

Cómo se aplica

Mantén fuera del agente decisiones que deben ser invariantes, como límites legales o validaciones de integridad. Restringe herramientas por rol, valida argumentos, registra acciones y requiere aprobación humana para operaciones económicas o irreversibles. El agente no debe cambiar features para persuadir al modelo.

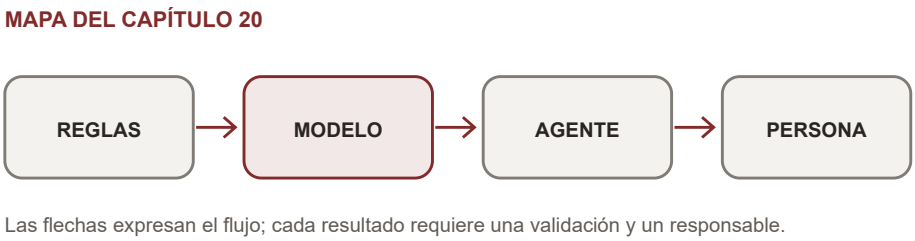


Figura 20.1 · Modelo, reglas, procesos y agentes: representación del flujo o decisión que explica este capítulo.

CASO

Ejemplo logístico: el modelo predice probabilidad de retraso; las reglas verifican que el pedido no esté cancelado; el agente resume eventos del TMS; el operador elige llamar al proveedor. Cada componente tiene propietario y registro.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Separar estimación, política, explicación y ejecución hace el sistema inspeccionable.

CAPÍTULO 21

Monitorear, renovar y cerrar el ciclo

> *El despliegue inicia la evaluación en condiciones reales.*

Monitorea disponibilidad, latencia, errores, distribución de entradas, datos faltantes, desempeño cuando llega la etiqueta y carga de revisiones. Drift de datos no demuestra por sí solo que cayó la calidad; puede ser cambio de mezcla que exige medir el resultado. Define umbrales, responsable, rollback y fecha de caducidad del modelo.

Cómo se aplica

Capstone ficticio: un distribuidor conecta ERP de lectura y WMS; predice demanda por SKU-tienda; compara baseline estacional, evalúa por temporada y piloto en pocas tiendas. Un servicio interno devuelve rango y versión; un agente resume cambios de inventario y propone borrador; el planificador aprueba. MLflow registra experimentos.

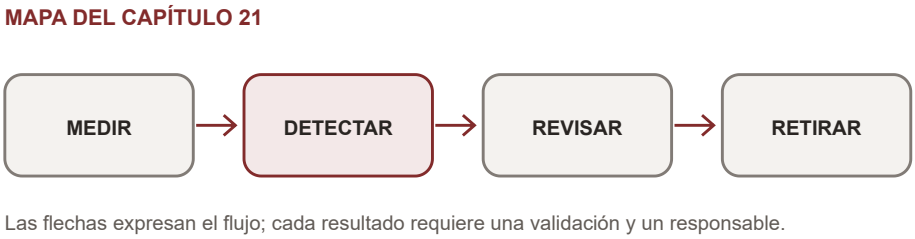


Figura 21.1 · Monitorear, renovar y cerrar el ciclo: representación del flujo o decisión que explica este capítulo.

CASO

Plan de salida: documentar propósito y exclusiones; congelar snapshot de prueba; revisión de seguridad y privacidad; despliegue gradual; comparar con control; auditar acciones; decidir continuar, corregir o retirar.

Qué revisar antes de avanzar

Registra quién crea la variable, cuándo se conoce, qué versión de datos se usó y quién puede cuestionar el resultado. Repite la evaluación en una ventana posterior y separa la métrica de validación de los resultados del piloto. Una cifra histórica no garantiza el mismo desempeño mañana.

RECUERDA

Un modelo responsable tiene criterio de parada, dueño operativo y alternativa manual probada.

CIERRE

Síntesis

Un problema de ML comienza con una decisión, no con un algoritmo. Se representa en una tabla cuyo corte temporal excluye el futuro; se compara con una línea base y se evalúa con métricas alineadas al coste de error. Los modelos supervisados, no supervisados y temporales ofrecen formas distintas de aprender; las redes neuronales son una parte del campo, no su definición completa.

En la empresa, la predicción se combina con reglas, optimización, políticas, aplicaciones y personas. El pipeline debe gobernar el acceso al ERP; el endpoint debe definir un contrato; y el sistema debe registrar versión, resultado, revisión y posibilidad de retiro. Un agente puede orquestar herramientas dentro de permisos; no reemplaza el juicio ni valida por sí mismo el modelo.

REFERENCIA

Glosario

Aprendizaje supervisado

Aprendizaje con ejemplos de entrada y resultado conocido.

Baseline

Método de referencia sencillo contra el que se compara una propuesta.

Calibración

Grado en que probabilidades estimadas coinciden con frecuencias observadas.

Característica

Variable de entrada disponible en el instante de predicción.

Clasificación

Predicción de una clase o puntuación asociada a clases.

Data leakage

Uso accidental de información que no estaría disponible al predecir.

Deriva

Cambio de datos, relaciones o condiciones entre periodos.

Entrenamiento

Ajuste de parámetros del modelo usando datos de ejemplo.

Etiqueta

Resultado objetivo asociado a un ejemplo.

Feature store

Sistema gobernado para compartir características calculadas.

Inferencia

Cálculo de una predicción con un modelo entrenado.

Machine Learning

Métodos que ajustan modelos a partir de datos para producir estimaciones.

MAE

Promedio del valor absoluto de los errores de regresión.

No supervisado

Métodos que buscan estructura sin una etiqueta objetivo dada.

Pipeline

Secuencia reproducible de extracción, transformación, evaluación y despliegue.

Probabilidad estimada

Puntuación probabilística dependiente de datos, modelo y validación.

Regresión

Predicción de una cantidad numérica.

Umbral

Límite elegido para convertir una puntuación en una acción o clase.

REFERENCIA

Fuentes

1. scikit-learn developers. Getting Started. https://scikit-learn.org/stable/getting_started.html. Consulta: 2026-10-18.
2. scikit-learn developers. User Guide. https://scikit-learn.org/stable/user_guide.html. Consulta: 2026-10-18.
3. XGBoost developers. Installation Guide. https://xgboost.readthedocs.io/en/stable/install.html. Consulta: 2026-10-18.
4. CatBoost developers. Python package installation. https://catboost.ai/docs/en/concepts/python-installation. Consulta: 2026-10-18.
5. LightGBM developers. Python Package Introduction. https://lightgbm.readthedocs.io/en/stable/Python-Intro.html. Consulta: 2026-10-18.
6. FastAPI contributors. First Steps. https://fastapi.tiangolo.com/tutorial/first-steps/. Consulta: 2026-10-18.
7. MLflow contributors. MLflow Tracking Server. https://mlflow.org/docs/latest/tracking/server/. Consulta: 2026-10-18.
8. MLflow contributors. MLflow Deployments. https://mlflow.org/docs/latest/deployment/. Consulta: 2026-10-18.
9. statsmodels developers. statsmodels documentation. https://www.statsmodels.org/stable/index.html. Consulta: 2026-10-18.
10. PyTorch contributors. PyTorch documentation. https://pytorch.org/docs/stable/index.html. Consulta: 2026-10-18.

COLOFÓN

Sobre esta colección

Aprender de los datos · Mapache · Explora señales y organiza hallazgos; la metáfora termina antes del aprendizaje estadístico y la decisión empresarial · 2026.

#	Título	Animal	Ángulo
I	Agentes de IA: De la idea a la producción	Pulpo	Inteligencia distribuida
II	Construyendo con Agentes de IA	Hormiga	Enjambre emergente
III	Agentes de IA: Una guía ilustrada	Cuervo	Uso inteligente de herramientas
IV	Patrones Arquitectónicos para Sistemas Multiagente	Abeja	Patrones de coordinación probados
V	Agentes de IA con MCP	Delfín	Comunicación y protocolo
VI	Agentes de IA en Acción	Zorro	Acción inteligente y adaptativa
VII	Agentes de IA en la práctica	Castor	Ingeniería orientada a producción
VIII	El Segundo Cerebro Corporativo	Ardilla	Conocimiento almacenado y recuperable
IX	La Federación de Cerebros	Suricata	Vigilancia distribuida
X	La Máquina de Predecir	Cachalote	Percepción construida desde señales y patrones
XI	Del texto al contexto	Murciélago	Encontrar señales parecidas sin confundirlas con hechos
XII	La red que aprende	Araña	Las conexiones aprenden patrones; cada arquitectura incorpora decisiones y límites distintos
XIII	**Aprender de los datos**	**Mapache**	**Explora señales y organiza hallazgos; la metáfora termina antes del aprendizaje estadístico y la decisión empresarial**
—	El Castor y el Plano — Spec-Driven Development con agentes	Castor	Construir siguiendo un plano vivo